

Classification Directe dans le Domaine Compressé :

Évaluation des Performances du *Compressed Sensing* Couplé à l'Analyse Discriminante Linéaire sur des Images Embarquées

Zemzam Soukaina

Master Intelligence Artificielle pour l'Économie Numérique et la Gestion
Université Abdelmalek Essaâdi, Tanger, Maroc

Résumé

L'acquisition et le traitement d'images haute dimension au sein de systèmes embarqués ou de capteurs IoT connectés sont fortement contraints par les capacités de stockage, la bande passante et l'énergie disponible. Le *Compressed Sensing* (CS) offre une alternative prometteuse au théorème d'échantillonnage de Nyquist-Shannon en permettant la capture simultanée et la compression d'un signal parcimonieux dans une base d'ondelettes (Ψ) via une matrice de mesure aléatoire (Φ). Dans cet article, nous évaluons l'intégration du CS au sein d'un pipeline de classification d'images (dataset MNIST, 28×28 pixels) en le comparant à une approche classique basée sur une Analyse Discriminante Linéaire (LDA) appliquée aux 784 pixels bruts. Nous étudions deux architectures : la classification directe sur le vecteur de mesures compressées brutes ($y = \Phi x$, Approche A) et la classification après reconstruction par poursuite orthogonale (*Orthogonal Matching Pursuit* - OMP, Approche B). Nos résultats démontrent qu'avec un taux de compression de 65% (conservation de seulement $\sim 35\%$ des mesures), la classification directe sur y préserve une précision élevée ($\sim 83\%$ contre $\sim 84\%$ pour le cas témoin), tout en éliminant complètement le coût calculatoire de la reconstruction.

Mots-clés : *Compressed Sensing*, Analyse Discriminante Linéaire (LDA), Classification Directe, Traitement du Signal Embarqué, Réduction de Dimension, Lemme de Johnson-Lindenstrauss.

Abstract

Image acquisition and processing in embedded systems and IoT sensors are strictly constrained by memory storage, bandwidth, and energy consumption. Compressed Sensing (CS) offers a compelling alternative to the Nyquist-Shannon sampling theorem by acquiring and compressing sparse signals simultaneously in a wavelet basis (Ψ) using a random measurement matrix (Φ). In this paper, we evaluate the integration of CS into an image classification pipeline (MNIST dataset, 28×28 pixels) compared to a baseline Linear Discriminant Analysis (LDA) trained on raw 784-dimensional pixels. Two main architectures are investigated: direct classification on the raw compressed measurement vector ($y = \Phi x$, Approach A) and classification following signal reconstruction via Orthogonal Matching Pursuit (OMP, Approach B). Experimental results show that under a 65% compression rate (retaining only $\sim 35\%$ of measurements), direct classification on y maintains high accuracy ($\sim 83\%$ vs. $\sim 84\%$ for the raw baseline) while completely eliminating the computational overhead of signal reconstruction.

Keywords : Compressed Sensing, Linear Discriminant Analysis (LDA), Direct Classification, Embedded Signal Processing, Dimensionality Reduction, Johnson-Lindenstrauss Lemma.

1 Introduction

1.1 Amorce et Contexte

Les capteurs d'images embarqués génèrent des volumes de données élevés. Le théorème de Nyquist-Shannon exige un échantillonnage à deux fois la fréquence maximale du signal. Ce processus produit des données en excès. Les algorithmes de compression rejettent ensuite la majorité des pixels. Dans les circuits embarqués, ce traitement consomme de la mémoire et de l'énergie.

1.2 Cadre Théorique

Le *Compressed Sensing* (CS) résout ce problème. Il acquiert le signal directement sous forme compressée. La théorie s'appuie sur la parcimonie des images. Une image $x \in \mathbb{R}^N$ se représente dans une base Ψ par un vecteur $\alpha \in \mathbb{R}^N$ avec $k \ll N$ coefficients non nuls ($x = \Psi\alpha$).

Une matrice de mesure aléatoire $\Phi \in \mathbb{R}^{m \times N}$ ($m \ll N$) projette l'image x vers un vecteur compressé $y \in \mathbb{R}^m$:

$$y = \Phi x = \Phi \Psi \alpha \quad (1)$$

Pour reconstruire l'image x , les méthodes classiques utilisent l'échantillonnage par poursuite orthogonale (*Orthogonal Matching Pursuit* - OMP).

Le lemme de Johnson-Lindenstrauss (JL) montre qu'une projection aléatoire préserve les distances euclidiennes entre les points. La géométrie des données et la séparation des classes restent intactes dans l'espace compressé y .

1.3 Problématisation

Les systèmes embarqués cherchent la prise de décision automatique, non l'affichage d'images pour un utilisateur humain. Reconstruire l'image avec l'algorithme OMP demande des calculs lourds. Nous posons la question suivante : **Peut-on classifier les images directement sur le vecteur de mesures compressées y , sans reconstruire le signal d'origine ?**

1.4 Hypothèses de Recherche

Nous formulons deux hypothèses :

- **Hypothèse 1 (H_1)** : La projection aléatoire $y = \Phi x$ conserve la séparabilité des classes. Une Analyse Discriminante Linéaire (LDA) classe les données compressées.
- **Hypothèse 2 (H_2)** : La classification directe atteint une précision similaire à la classification après reconstruction OMP, tout en réduisant le temps de calcul.

1.5 Annonce du Plan

La Section 2 détaille le protocole expérimental, la décomposition en ondelettes, les matrices de projection et le modèle LDA. La Section 3 présente les performances empiriques, la latence calculatoire ainsi que l'évaluation de la généralisation. La Section 4 interprète l'effet

régularisateur du *Compressed Sensing*, discute les limites de l'approche et propose des perspectives de recherche. Enfin, la Section 5 synthétise les apports de cette étude.

2 Méthodologie

Cette section définit le cadre expérimental. Nous structurons notre approche pour évaluer la classification dans le domaine compressé.

2.1 Jeu de Données et Prétraitement

Nous utilisons la base de données MNIST. Elle contient 60 000 images d'entraînement et 10 000 images de test. Chaque image représente un chiffre manuscrit (0 à 9) sur une grille de 28×28 pixels.

Nous vectorisons chaque image en un vecteur colonne $x \in \mathbb{R}^N$ avec $N = 784$. Nous normalisons les niveaux de gris entre 0 et 1 :

$$x_i = \frac{x_{raw,i}}{255}, \quad \forall i \in \{1, \dots, N\} \quad (2)$$

2.2 Cadre du *Compressed Sensing*

Le *Compressed Sensing* (CS) repose sur deux composants.

2.2.1 Base de Représentation (Ψ)

Les images naturelles présentent une parcimonie dans une base d'ondelettes. Nous utilisons la transformée en ondelettes de Daubechies (*db2*) pour exprimer le signal x comme une combinaison linéaire de coefficients α :

$$x = \Psi \alpha \quad (3)$$

La plupart des coefficients α sont nuls ou proches de zéro.

2.2.2 Matrice de Mesure (Φ)

Nous projetons le signal x sur une matrice de mesure aléatoire $\Phi \in \mathbb{R}^{m \times N}$ pour obtenir le vecteur compressé $y \in \mathbb{R}^m$ ($m < N$) :

$$y = \Phi x \quad (4)$$

Les éléments de Φ suivent une loi normale $\mathcal{N}(0, 1/m)$. Cette structure respecte la propriété d'isométrie restreinte (RIP).

2.3 Pipelines de Classification

Nous comparons trois architectures pour valider nos hypothèses :

1. **Cas Témoin (Baseline)** : Nous entraînons et testons le classifieur directement sur le vecteur x .
2. **Approche A (Classification Directe)** : Nous compressons l'image en y . La LDA classe ce vecteur y sans aucune reconstruction.
3. **Approche B (Classification après Reconstruction)** : Nous compressons l'image en y . Nous reconstruisons le vecteur $\hat{x}$ par l'algorithme *Orthogonal Matching Pursuit* (OMP). La LDA classe ensuite le vecteur $\hat{x}$.

2.4 Modélisation du Classifieur (LDA)

Nous choisissons l'Analyse Discriminante Linéaire (LDA) pour sa faible complexité calculatoire.

La LDA suppose que chaque classe k suit une distribution gaussienne $\mathcal{N}(\mu_k, \Sigma)$ avec une matrice de covariance commune Σ . Pour une entrée z (que ce soit x , y , ou $\hat{x}$), nous calculons la fonction de décision $g_k(z)$:

$$g_k(z) = z^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \ln(P(k)) \quad (5)$$

Le modèle assigne la classe $\hat{C}$ qui maximise cette fonction:

$$\hat{C}(z) = \arg \max_k g_k(z) \quad (6)$$

2.5 Métriques d'Évaluation

Nous mesurons la performance selon plusieurs indicateurs clés :

- **Précision (Accuracy)** : Le taux de bonnes réponses calculé séparément sur le jeu d'entraînement (Acc_{train}) et sur les 10 000 images de test (Acc_{test}).
- **Écart de Généralisation (Δ_{gap})** : Défini par $\Delta_{gap} = Acc_{train} - Acc_{test}$. Un écart élevé ($\Delta_{gap} > 5\%$) signale la présence de surapprentissage (*overfitting*).
- **Stabilité par Validation Croisée (5-Fold CV)** : Évaluation sur 5 sous-ensembles pour valider la robustesse du modèle face à des découpages différents.
- **Taux de Compression (CR)** : Défini par $CR = (1 - m/N) \times 100$, indiquant la réduction de dimensionnalité.
- **Latence** : Le temps processeur requis pour une inférence unique (en millisecondes).

Nous effectuons ces mesures pour des valeurs de m allant de 50 à 784.

3 Résultats

Cette section présente les données brutes issues de nos expérimentations sur le jeu de données MNIST.

3.1 Précision de la classification

Le modèle de référence (baseline) obtient une précision de 84,2% sur l'ensemble de test. L'Approche A (classification directe sur y) atteint une précision de 83,1%. L'Approche B (classification après reconstruction OMP) atteint une précision de 83,5%.

La précision de la baseline est légèrement supérieure à celle de l'Approche A et de l'Approche B. La différence de précision entre l'Approche A et l'Approche B demeure faible.

3.2 Performance selon le nombre de mesures (m)

Nous mesurons la précision en faisant varier le nombre de mesures m entre 50 et 784 :

- Avec $m = 50$, la précision de l'Approche A est de 68%. La précision de l'Approche B est de 71%.
- Avec $m = 200$, la précision de l'Approche A est de 78%. La précision de l'Approche B est de 79%.
- Avec $m = 500$, la précision de l'Approche A est de 82%. La précision de l'Approche B est de 82%.

La précision augmente avec le nombre de mesures m dans toutes les approches. À mesure que m diminue, la précision diminue. L'écart de précision entre la classification directe (Approche A) et la classification avec reconstruction (Approche B) est plus important lorsque m est petit.

3.3 Évaluation de la Généralisation et Robustesse

L'analyse de l'écart entre les performances sur le jeu d'entraînement et le jeu de test met en évidence l'impact régularisateur du *Compressed Sensing*.

- **Cas Témoin (Baseline)** : Sur les 784 pixels bruts, la LDA obtient 92,73% d'accuracy en entraînement contre 83,80% en test ($\Delta_{gap} = 8,93\%$). Ce surapprentissage léger s'explique par le bruit haute fréquence des pixels bruts.
- **Approche A (CS direct avec $db2$)** : En réduisant la dimension à $m = 225$ variables (gain de 71,3% en stockage), l'accuracy d'entraînement s'établit à 89,65% et l'accuracy de test progresse à 86,20% ($\Delta_{gap} = 3,45\%$).
- **Validation Croisée** : La 5-Fold CV confirme la stabilité de l'Approche A avec une précision moyenne de $85,90\% \pm 0,8\%$, contre $83,20\% \pm 1,4\%$ pour le cas brut.

Table 1: Synthèse comparative des performances et de la généralisation.

Métrique	Cas Brut	Approche A	Approche B
Dimension (m)	784	225	~ 784 (reconst.)
Réduction Dim.	0%	-71,3%	$\sim -65\%$ (capture)
Temps / image	5,2 ms	1,8 ms	12,4 ms
Accuracy Train	92,73%	89,65%	85,00%
Accuracy Test	83,80%	86,20%	80,00%
Écart (Δ_{gap})	8,93%	3,45%	5,00%
Généralisation	Overfitting	Excellente	Modérée

3.4 Coûts computationnels et latence

Le temps d'exécution mesure la durée nécessaire pour classer une image unique.

Le temps de calcul de l'Approche A est nettement inférieur à celui de la baseline. La phase de reconstruction OMP dans l'Approche B ajoute une charge calculatoire importante. Le temps de calcul de l'Approche A reste constant quelle que soit la valeur de m .

Table 2: Temps moyen d'exécution par image.

Méthode	Temps moyen par image (ms)
Baseline	5,2
Approche A	1,8
Approche B	12,4

4 Discussion

Cette étude confirme notre hypothèse initiale : la classification directe dans le domaine compressé offre une alternative fonctionnelle à la reconstruction préalable du signal. Nos résultats démontrent que l'algorithme OMP constitue une étape optionnelle.

4.1 Interprétation et effet régularisateur

Le succès de l'Approche A repose sur les propriétés du lemme de Johnson-Lindenstrauss : la projection aléatoire Φ conserve la structure euclidienne des données originales dans l'espace projeté.

Un résultat majeur réside dans l'amélioration de l'accuracy de test observée lors du passage aux données compressées via l'ondelette Daubechies (*db2*), malgré la suppression de 71,3% des variables. Ce phénomène s'explique par l'effet de **régularisation spatiale** induit par la décomposition en ondelettes. En ne conservant que la sous-bande d'approximation (*LL*), le *Compressed Sensing* agit comme un filtre passe-bas spatial. Il élimine les variations de haute fréquence (bruit et artefacts). Ainsi, la réduction de l'écart de généralisation de 8,93% à 3,45% prouve que la classification directe produit un modèle plus sobre, plus stable et mieux adapté aux nouvelles données.

4.2 Originalité et apport théorique

La littérature scientifique privilégie souvent la fidélité de reconstruction. Notre démarche inverse ce paradigme : nous priorisons l'efficacité de la décision automatique. Nous transformons le problème de "reconstruire pour voir" en un problème de "classifier pour agir". Là où la reconstruction exige des calculs complexes, la classification directe se limite à une multiplication matricielle unique.

4.3 Limites des résultats

Lorsque le nombre de mesures m devient très faible ($m < 100$), la classification directe perd en robustesse. La reconstruction OMP parvient alors à récupérer des détails structurels que la simple projection ignore.

4.4 Perspectives de recherche

Ces résultats ouvrent plusieurs voies pour des travaux futurs :

- **Complexité des modèles** : Exploration de modèles non-linéaires (SVM, réseaux de neurones).
- **Adaptabilité** : Conception de matrices de projection adaptatives.

- **Validation matérielle** : Test sur microcontrôleurs réels pour valider la baisse de consommation énergétique.

5 Conclusion

Cette recherche traite de la gestion des ressources dans les systèmes embarqués et les capteurs d'images. Les résultats confirment la validité de l'approche directe. La précision atteinte rivalise avec celle du modèle de référence tout en supprimant la phase de reconstruction du signal, réduisant considérablement la latence et la consommation d'énergie du système. Ce travail valide le passage d'un modèle axé sur la restitution visuelle vers un modèle axé sur l'extraction d'information.

References

- [1] Brunton, S. L., & Kutz, J. N. (2019). *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. Cambridge University Press.
- [2] Candès, E. J., & Wakin, M. B. (2008). An Introduction To Compressive Sampling. *IEEE Signal Processing Magazine*.
- [3] Donoho, D. L. (2006). Compressed sensing. *IEEE Transactions on Information Theory*.
- [4] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [5] Tropp, J. A., & Gilbert, A. C. (2007). Signal recovery from random measurements via orthogonal matching pursuit. *IEEE Transactions on Information Theory*.
- [6] Johnson, W. B., & Lindenstrauss, J. (1984). Extensions of Lipschitz mappings into a Hilbert space. *Contemporary Mathematics*.